

Mentoria de IA aplicada · **Aula 2 de 8**

Além do chat: System One e o Jev

Decisões tipadas, confiança e calibração

Hoje

Ao final, você consegue:

- dizer se um problema pede **texto** ou só uma **decisão**
- obter uma decisão **tipada** de um LLM comum
- obter um sinal de **confiança** e **medir** se ele presta
- ler um anúncio de IA com **olhar crítico**

Roteiro (40 min)

1. Recap da M1
2. System One e o Jev
3. Strings x tipos
4. Livre x tipado, ao vivo
5. Leitura crítica
6. Gerativo ou decisão?

Depois: 15 min de discussão

O que vocês trouxeram da M1

Classificar a notícia em **texto livre**, com temperatura 1.5:

- Relevante. Categoria: ferramentas.
- Relevante**s** → Categoria: ferramentas
- Relevante. Categoria: ferramentas. **JUSTIFICATIVA:** ...

Quem tentou ler isso com código? Quantas respostas conseguiu interpretar?

Muita "IA" em software não precisa gerar texto: precisa tomar uma **decisão** que o código consiga usar.

Uma decisão útil tem **tipo** e **confiança**. E confiança só vale se for **medida**.

1 · System One e o Jev

Sistema 1 e Sistema 2

Sistema 1

Rápido, automático, intuitivo.

Reconhecer um rosto. Perceber que alguém está bravo.

Sistema 2

Lento, deliberado, trabalhoso.

Fazer uma conta de cabeça. Comparar dois planos de saúde.

Muitas decisões dentro de software são de **Sistema 1**: olhar um texto e julgar rápido.

O Jev, segundo o anúncio

- Lançado pela TypeSafe AI em **15/set/2026**, em **early access**
- **Não gera texto**: recebe um estado e perguntas tipadas, devolve **respostas tipadas com probabilidades**
- Gera **tudo de uma vez**, não um token por vez
- Treinado com **RLCD** (aprendizado por reforço para decisões calibradas), não RLHF/RLVR
- Pensado como um **"if inteligente"**: classificar, rotear, pontuar, extrair, guardrail, juiz

LLM × System One (tabela do post)

	LLM	System One (Jev)
Treinado com	RLHF / RLVR	RLCD
Saída	texto	valores tipados
Como gera	um token por vez	em paralelo
Velocidade	3 s a 329 s	70 ms a 500 ms
Confiança	"confiante demais, inconsistente"	"calibrada"
Bom para	humano no meio, demos	workflows, tempo real

Três tipos de pergunta

Choice

Escolha uma opção da lista.

→ opção, probabilidade de cada uma, confiança

Score

Dê uma nota em níveis.

→ nota, probabilidade de cada nível, confiança

Noul

Sim ou não?

→ probabilidade de "sim" (0 a 1)

Confiança $\neq$ probabilidade: 88% entre 3 opções → confiança **0,82**. 50% entre 2 opções → confiança **0**.

2 · Strings × tipos

Dá para fazer com um LLM comum?

Saída estruturada: como funciona por dentro

- Você manda um **schema** (Zod → JSON Schema) e o provedor garante o formato
- A cada token, o provedor **zera a probabilidade** do que quebraria o schema e sorteia entre o resto
- Parecido com o top-p da Aula 1, mas o filtro é "o que é válido", não "o que é provável"

O schema **não muda o que o modelo pensa**. Ele só **proíbe tokens**.

A armadilha do rótulo

demo:armadilha-do-rotulo

Schema { "rotulo": modelos | ferramentas | pesquisa | regulacao | mercado | irrelevante }

Notícia	Esperado	O que o modelo queria escrever	Escolhido
n02	ferramentas	"IA" 71,7% · "re" 15,5%	regulacao
n03	pesquisa	"IA" 72,5% · "re" 20,5%	regulacao

O modelo queria escrever "IA" ou "relevante". A única opção que começa com "re" é **regulacao**.

3 · Livre x tipado, ao vivo

A mesma notícia, dois jeitos

demo:livre-vs-tipado

Texto livre (3x, temperature 0.7)

"Relevante. Categoria: ferramentas.

Justificativa: A mudança na cobrança por tokens em cache afeta diretamente..."

71–79 tokens · 3,6–4,6 s

Decisão tipada (Zod)

```
{ "relevante": true,  
  "categoria": "ferramentas",  
  "confianca": 0.99 }
```

33 tokens · 2,2 s

Notícia n06 (rótulo humano: **mercado**). Os dois erraram do mesmo jeito.

Nas 20 notícias do projeto

	Texto livre (M1)	Decisão tipada (M2)
Saídas que o código consegue usar	20/20, com um parser cuidadoso	20/20, sem parser
Acertos	15/20 (75%)	15/20 (75%)
Latência média	~4,8 s	~2,5 s

Mesma acurácia. O ganho do tipado é **contrato, custo e latência**, não inteligência.

A confiança acompanha o acerto?

demo:calibracao

Confiança média



Acurácia



Os **5 erros** vieram com confiança de **0,90 a 0,99**.

Aceitar só se confiança $\geq$	Cobre	Acerta
0,90	100%	75%
0,95	95%	79%
0,99	60%	92%

ECE $\approx$ **0,22** (0 = calibrado)

Três jeitos de pedir confiança a um LLM

Logprobs

Probabilidade dos tokens.

Aqui: **~100%** no booleano em todas. Não serviu.

Autoavaliação

Campo confiança no JSON.

Aqui: 0,90–0,99 em tudo, inclusive nos erros.

Autoconsistência

Rodar 5x e contar votos.

Aqui: **5 de 5** também nos erros.

Modelos pós-treinados tendem a ficar **confiantes demais**. Confiança só vale **depois de medida**.

4 • Leitura crítica

Números de fornecedor

O que o próprio post ressalva

- A consulta de demonstração é **muito simplificada**; a entrada curta **favorece** o modelo deles
- Os ganhos nos workflows devem estar **no topo** do que se vê no mundo real
- Os workflows foram montados pelo **time do próprio produto**: "pode haver viés"
- Os LLMs comparados passaram por um **wrapper deles**, que os deixa mais lentos e caros
- "0% de erro de tipo" **não é medido**: é garantido por construção

Onde a própria documentação diz que ele falha

- Leitura **literal** das instruções
- **Contas** e contagens
- Comparação de **datas**
- Perguntas com várias indireções
- Estado grande com muito detalhe irrelevante
- Conteúdo adversarial
- **Ordem** das opções numa Choice
- **Gerar texto** ("use um modelo gerativo")

"Tipo sempre válido" $\neq$ "decisão certa". **Meça no seu caso** — inclusive o do Jev.

Gerativo ou decisão?

A saída é...	Exemplo	Use
texto para uma pessoa ler	resumo, e-mail, resposta de chat	LLM gerativo
um valor de um conjunto fechado que o código usa	categoria, sim/não, nota	decisão tipada
as duas coisas	classificar e justificar	decisão + texto, em campos separados

Discussão

15 minutos

Para conversar

1. Um sistema do seu dia a dia com IA: a saída é texto para uma pessoa ou uma decisão que o código usa?
2. Se o tipado acertou o mesmo tanto que o texto livre, o que ganhamos com ele?
3. O modelo disse 0,99 e errou. O que você faria antes de usar essa confiança para automatizar algo?
4. Por que "nunca erra o tipo" é verdade por construção e não é o mesmo que acertar?
5. Que evidência você pediria antes de trocar um LLM por um modelo de decisão como o Jev?

Para a próxima aula

Exercício

Confiança (logprobs, escolha, votação) e calibração (Brier, ECE, cobertura)

```
pnpm -F @mentoria/ex02-decisoes test
```

Desafio: [temperature scaling](#)

Projeto final · M2

classificarTipado : Zod + confiança + regras no código

```
pnpm -F @mentoria/curador m02:comparar
```

Traga a tabela "A confiança acompanha o acerto?"

Próxima aula · **Prompt, Evals e Guardrails**

20 notícias não bastam. Como saber se o seu prompt **melhorou** de verdade?

Datasets rotulados, métricas, LLM-as-judge, regressão e guardrails que impedem publicar sem fonte.