Mentoria de IA aplicada · **Aula 7 de 8**

Human-in-the-loop e automação

Quando a máquina para e espera alguém decidir

Hoje

Ao final, você consegue:

- dizer **onde** pôr uma pessoa no circuito
- usar os **níveis de autonomia**
- pausar com `interrupt()` e retomar com `Command`
- evitar as **armadilhas** da retomada
- **medir** a revisão e calibrar o limiar

Roteiro (40 min)

1. Por que HITL
2. `interrupt()` e `Command`
3. Demo: aprovação
4. O que automatizar e como medir

Depois: 15 min de discussão

Automatize o que dá para **desfazer**. Peça aprovação para o que **não dá**.

Comece com mais revisão e vá soltando com dados.

1 · Por que HITL

Human-in-the-loop: humano no circuito

Três motivos para chamar uma pessoa

Não volta atrás

Publicar, pagar, apagar, mandar mensagem ao cliente

Incerteza

Confiança **calibrada** (Aula 2) baixa → alguém olha

Responsabilidade

Negar um pedido, publicar em nome da empresa: alguém responde

Piloto automático: voa sozinho quase todo o tempo; decolagem, pouso e o imprevisto ficam com os pilotos.

O outro lado: viés de automação

A tendência de **aceitar a sugestão da máquina** e parar de procurar sinais contrários.

- Aparece em **iniciantes e especialistas**
- Em pessoas sozinhas e em **equipes**
- **Não some** com treinamento ou instruções

Então

- **Não** peça aprovação de tudo
- Mostre **por que** parou e a **evidência**
- **Meça** se a revisão é real

Parasuraman & Manzey (2010), Complacency and Bias in Human Use of Automation, Human Factors 52(3)

Cinco níveis de autonomia

Nível	Papel da pessoa	O agente…
1	**Operadora**	ajuda quando é chamado
2	**Colaboradora**	planeja e executa junto
3	**Consultora**	toma a iniciativa e consulta nas decisões importantes
4	**Aprovadora**	trabalha sozinho; chama a pessoa num bloqueio ou para aprovar o que tem consequência
5	**Observadora**	é totalmente autônomo; a pessoa só acompanha

O nível é uma decisão de desenho, separada da capacidade do modelo.

Feng, McDonald & Zhang (2025), Levels of Autonomy for AI Agents, arXiv:2506.12469

2 · `interrupt()` e `Command`

demo:armadilha

Pausar e retomar

```
.addNode("pedir_aprovacao", (estado) => {
  const resposta = interrupt({
    pedido: estado.pedido,
    analise: estado.analise,
  });              // ⏸ pausa e salva
  // … segue com a resposta
})
```

```
await grafo.invoke(
  new Command({ resume: { acao: "aprovar" } }),
  { configurable: { thread_id } })
```

O que acontece

1. O estado vai para o **checkpoint**
2. O valor da pausa aparece em `__interrupt__`
3. A resposta pode vir de **outro processo**, dias depois
4. `resume` vira o **retorno** do `interrupt()`

Aprovar, editar, rejeitar

Resposta	No curador	No reembolso
aprovar	o item vai para a redação	paga o valor sugerido
editar	outra categoria ou título	paga outro valor
rejeitar	o item sai, com o motivo	nega o reembolso

- **Valide a resposta com schema**, como a saída de um LLM: um "sim" solto não vira aprovação
- Resposta inválida → **pergunte de novo**, mostrando o erro
- **Registre** cada decisão: vira métrica e caso de avaliação

As armadilhas da retomada

O nó roda de novo

Ao retomar, o nó reexecuta **desde o começo**. O que vem antes do `interrupt()` acontece outra vez.

`demo:armadilha` : **2 e-mails** no jeito errado, **1** no certo.

- Efeito externo e LLM caro: **depois** da pausa, ou num nó separado
- **Nada de** `try/catch` em volta do `interrupt()`
- Várias pausas em paralelo: responda com `{ id: resposta }`; dá para responder só algumas
- A ordem dos `interrupt()` num nó **importa**

docs.langchain.com/oss/javascript/langgraph/interrupts

3 · Demo: aprovação

demo:aprovacao · m07:edicao

Três pedidos, três níveis

R$ 40

confiança 0,97

automático: paga sozinho

R$ 350

confiança 0,92

aprovação: ⏸ você decide

R$ 5.000

acima do limite

escala: ninguém paga aqui

A política é **código**: valor, confiança e sugestão → nível. Fácil de testar e de mudar.

O curador pausado



Antes da aula · `--nova`

~13 min de modelo até a 1ª pausa. Saí com **[s]**: o grafo ficou esperando no **arquivo**

Na aula · outro processo

4 pausas esperando: n40, n17, n13, n38 (todas por guardrail). Decidir → aprovar a edição → publicar

Resultado da revisão

Pausas	Intervenção	Override	Retomada
5 (4 itens + a edição)	**13%** dos 32 avaliados	**80%** das decisões	**~1 s**, 0 chamadas ao modelo

- 4 rejeitados com motivo; a edição de **9 itens** aprovada e publicada
- **Override de 80% é ruim?** Aqui, não: a pessoa **concordou com o guardrail** e discordou do classificador. Defina **contra qual proposta** você mede

4 · O que automatizar e como medir

Três perguntas por etapa

1. **Dá para desfazer?** Rascunho, sugestão: sim. Pagamento, publicação: não
2. **Quanto custa um erro?** Um item fora do tema × um reembolso de R$ 5.000
3. **A confiança é calibrada e há histórico?** Sem dados, mais revisão; com dados, solte aos poucos

Comece no nível 4 e suba com dados. Cada decisão humana registrada vira histórico.

Três números

Métrica	Conta	Indica
Intervenção	itens que precisaram de gente ÷ itens	o custo humano
Override	editou ou rejeitou ÷ decisões	quanto a pessoa discorda da máquina
Tempo de decisão	segundos por decisão	o custo de cada pausa

- Intervenção alta + override baixo → hora de **automatizar mais**
- Override alto → a máquina erra; **melhore o modelo ou a política**
- Override ~0 + decisões em 2 s → **carimbo?** Teste com um caso que deveria ser rejeitado

Calibrar o limiar com dados

Limiar	Cobertura (automático)	Precisão
0,99	20%	100%
0,97	30%	100%
0,95	50%	**80%**
0,90	70%	**86%**
0,80	90%	67%

Precisão mínima de 85% → limiar **0,90**: 70% automático. **A precisão não cai em linha reta**: olhe a curva inteira.

Histórico fictício do desafio do exercício (10 pedidos)

Discussão

15 minutos

Para conversar

1. Que decisão do seu trabalho seria **100% automática**, qual pediria **aprovação** e qual **nunca** ficaria com uma máquina?
2. Quem aprova 99% sem mudar nada: o processo está bom ou a revisão virou **carimbo**? Como saber?
3. A pausa da edição inteira vale o tempo de alguém **toda semana**?
4. Quem define os limites da política (R$ 100, R$ 2.000, 0,9)? Com que dados?
5. Uma pausa pode durar **dias**. O que acontece com o mundo enquanto isso?

Para a próxima aula

Exercício

Reembolso com níveis de autonomia

```
pnpm -F @mentoria/ex07-hitl test
```

Desafio: calibrar o limiar

Projeto final · M7

Revise e publique uma edição

```
pnpm -F @mentoria/curador m07:edicao
```

Traga as métricas de revisão

Próxima aula · **Deploy e operação**

E se o curador rodasse sozinho, toda semana, na nuvem?

Agendamento, rastreamento, custo por edição, evals no CI e rollback de prompt.