Mentoria de IA aplicada · **Aula 8 de 8**

Deploy e operação

O curador rodando sozinho, toda segunda, num lugar que você não vê

Hoje

Ao final, você consegue:

- escolher **onde rodar** e tratar os limites como requisito
- pôr um fluxo **agendado** num Worker
- **rastrear** custo e latência por execução
- **versionar** o prompt, com portão e **rollback**
- montar um **CI** com duas velocidades
- escrever um job que **aguenta produção**

Roteiro (40 min)

1. Empacotar e escolher a plataforma
2. Rastreio, custo e latência
3. Versão do prompt e rollback
4. Evals em CI
5. Demo: o cron no Worker

Depois: discussão + retrospectiva

Em produção, o que importa é o que você consegue **ver** e **desfazer**.

Escreva o job supondo que ele vai rodar duas vezes, falhar no meio e custar mais do que você pensou.

1 · Empacotar e escolher a plataforma

Onde o curador pode morar

Precisa de	Workers	Apps Script	Sites
Rodar TypeScript com AI SDK, LangGraph, Zod	**sim**	não	não
Rodar agendado	**sim** (Cron Triggers)	sim	não
Guardar estado entre execuções	**sim** (KV, D1)	sim	não

- **Empacotar:** não há disco. Feeds, skill e fontes entram **no pacote**, como texto
- **Variável** para o que muda por ambiente; **segredo** para o que é secreto (`wrangler secret put`)

Os limites viram requisito

Limite	Gratuito	O que mudou no curador
Chamadas externas por execução	**50**	32 notícias ≈ 70 chamadas: não cabe → **8 notícias**
CPU por execução	10 ms	esperar o modelo **não conta**
Duração de um cron	15 min	edição local com 32 notícias passa disso
Escrita no KV, mesma chave	1 por segundo	checkpoint gravado **uma vez**, no fim

Coletor virou código: às 9h de segunda ninguém olha a trajetória de um agente (Aula 4).

developers.cloudflare.com/workers/platform/limits · kv/platform/limits

2 · Rastreio, custo e latência

m08:operar execucoes

Um evento por chamada ao modelo

```
observarChamadas((e) => eventos.push(e));

comAtributos({ papel: "redigir", alvo: "n13" },
  () => papeis.redigir("n13"));
```

```
// um evento (médias do redator na demo)
{ papel: "redigir", alvo: "n13",
  tokensEntrada: 152, tokensSaida: 49,
  latenciaMs: 9839, prompt: "embutida" }
```

Por que aqui

Toda chamada passa pelo `@mentoria/llm`: é o **único lugar** para medir

O contexto atravessa os `await` (AsyncLocalStorage): 8 classificações em **paralelo** não se misturam

O rastro real de uma edição

Papel	Chamadas	Tokens saída	p50	p95
classificar	8	260	15 s	24 s
redigir	6	295	10 s	61 s
revisar	6	**3.747**	**72 s**	**173 s**
total	20	4.302	17 s	149 s

O **revisor** gerou **87%** dos tokens de saída. Com saída em JSON schema, o Ollama contou **758 tokens** para uma resposta de 326 caracteres (sem schema: 152).

Custo e latência: como ler

Custo

tokens × preço por milhão

- **Estimar** (caracteres ÷ 4) é para **teto**
- **Medir** (`usage` do provedor) é para **fatura**
- Modelo local: preço zero; o custo é **tempo e máquina**

Latência

- **p50:** a experiência típica
- **p95:** os casos ruins, que estouram o limite
- **Soma ≠ duração:** 829 s somados numa execução de 245 s (chamadas em paralelo, fila no modelo local)

3 · Versão do prompt e rollback

m08:avaliar · m08:operar promover

O prompt é código que muda o comportamento

1. **Versão imutável com hash:** mudou o texto, é outra versão
2. **Portão antes de ativar**, em duas camadas:
   - **absoluto** (CI): macro-F1 ≥ 0,8 e nenhum caso especial publicado
   - **relativo** (Worker): não pode ser **pior que a versão no ar**, com o mesmo modelo
3. **Cada execução registra** qual versão rodou
4. **Rollback sem deploy:** a versão ativa é um ponteiro no KV

O **modelo** faz parte da versão: trocar o modelo muda tudo.

O portão pegou uma regressão de verdade

Versão	Mudança	macro-F1	CI (≥ 0,8)	Worker (vs. ativa)
v1	a skill da Aula 4	**0,967**	passa	**ativada**
v2	"considere relevante tudo que mencione IA"	0,852	**passa**	**barrada**: pior que 0,967
v1.1	uma palavra a mais	0,967	passa	ativada → **revertida** para v1

Avaliar uma versão: **~1,5 min** (40 notícias rotuladas).

O que o rollback não desfaz

Volta:

- o prompt (ponteiro no KV)
- o código (`wrangler rollback`, últimas 100 versões)

Não volta:

- dados gravados (KV, D1, filas)
- a edição já publicada
- o e-mail já enviado

Implantação gradual

`wrangler versions deploy` com porcentagem: **10%** na nova, 90% na antiga

No prompt, o mesmo: **canário** (desafio do exercício)

developers.cloudflare.com/workers/configuration/versions-and-deployments/rollbacks

4 · Evals em CI

Duas velocidades

	Testes offline	Eval com modelo
Quando	todo push e PR	prompt, eval ou dataset mudaram
Modelo	simulado	o de verdade (Ollama no runner)
Tempo	segundos (49 s o job todo)	**~6 min** (eval: 257 s)
Pega	código quebrado, contrato	regressão de qualidade

`.github/workflows/ci.yml` · `.github/workflows/eval-prompt.yml`

Reprovou no portão → **PR vermelho**.

5 · Demo: o cron no Worker

m08:dev · m08:operar

O curador como Worker

```
Cron (seg 9h) ─► scheduled() ─► grafo da Aula 7 (checkpoint no KV) ─► pausa ─► registra execução + rastro
HTTP (editor)  ─► GET /pendentes · POST /retomar ─► Command({ resume }) ─► publica no KV
```

Antes da aula

`m08:operar rodar` → ~4 min, 20 chamadas, **1 pausa** (`n39` , sem fonte)

Na aula

Rejeitar `n39` , aprovar a edição → **publicada** · 0 chamadas ao modelo

Disparar o cron de novo → **pulada** (já rodou hoje)

Um job que aguenta produção (o exercício)

Situação	O job faz
O cron disparou **duas vezes**	idempotência: o dia já deu "ok" → não faz nada
429 / 503	tenta de novo: espera 1 s, 2 s, 4 s
Resposta **fora do schema**	não insiste: tentar de novo não melhora
Entrada **enorme**	teto de custo estimado: nem chama

Retry numa camada só: se cada camada tenta de novo por conta própria, a carga se multiplica.

Amazon Builders' Library, Timeouts, retries, and backoff with jitter

Discussão

15 minutos · e uma retrospectiva

Para conversar

1. Que job com IA do seu trabalho rodaria **agendado**? E se rodasse **duas vezes**?
2. Quem decide **promover** uma versão de prompt: o CI, uma pessoa, os dois?
3. O revisor custa **87%** dos tokens de saída. Tirar, trocar por modelo menor ou por regras? Como saber se a qualidade caiu?
4. O que no seu sistema **não volta** com rollback?
5. **Retrospectiva:** das oito aulas, o que você usaria **amanhã**? O que ficou faltando?

Para fechar

Exercício

Job diário que aguenta produção

```
pnpm -F @mentoria/ex08-operacao test
```

Desafio: canário

Projeto final · M8

O curador no Worker + versões do prompt

```
pnpm -F @mentoria/curador m08:dev
```

Leitura extra: monitoramento em produção

Mentoria de IA aplicada · **fim da trilha**

Do token ao sistema em produção

LLMs, decisões tipadas, evals, skills e agentes, MCP, grafos, humanos no circuito e operação.